

# Assignment 3 Report

고려대학교 컴퓨터학과  
정경륜

## 1. assign\_3\_skeleton.m 코드 설명

$$g = \frac{1}{1 + |\nabla \hat{I}|^p}$$

먼저  $g$ 를 계산하기 위해서  $\hat{I}$ 을 구해주어야 한다.  $\hat{I}$ 은 input image인  $I$ 에 gaussian filter를 적용시킨 것이다. 이를 구하기 위해선 아래와 같이 matlab 내장 함수인 `imfilter`를 사용하여 구할 수도 있고 혹은 직접 구현을 할 수도 있다.

```

39  % TODO -----
40  % -----
41  % Get smoothed version of the input Image
42  % -----
43  % Use matlab function
44  h = fspecial('gaussian',5,1.0);
45  gaussian_blurred = imfilter(Img,h,'symmetric');
46  I = gaussian_blurred;

```

직접 구현하게 된다면 assignment2에서 수행했던 LPF를 가져와서 아래와 같이 사용하면 된다. 해당 과제에서 수행했던 filter의 종류는 butter worth filter이기 때문에 gaussian filter로 활용하고 싶다면 order를 1에 가깝게 설정해야 한다.

```

47  % -----
48  % Use LPF from assignment2
49  % Get size
50  dimX = size(Img,1);
51  dimY = size(Img,2);
52  % Padding
53  PQ = size(Img)*2;
54  F = fft2(Img,PQ(1),PQ(2));
55  F = fftshift(F);
56  % figure,imshow(log(1+abs((F))), []);
57  G = F;
58  D = zeros(PQ(1), PQ(2));
59  H = zeros(PQ(1), PQ(2));
60  centerP = PQ(1)/2;
61  centerQ = PQ(2)/2;
62  %
63  D0=30;
64  n=1;
65  %
66  for x=1:PQ(1)
67      for y=1:PQ(2)
68          D(x,y)= sqrt((x-centerP)^2 + (y-centerQ)^2);
69          H(x,y)=1/(1+(D(x,y)/D0)^(2*n));
70      end
71  end
72  % Low pass filtering
73  G = G.*H;
74  % figure,imshow(log(1+abs((G))), []);
75  G = ifftshift(G);
76  I = ifft2(G);
77  I = I(1:dimX, 1:dimY);
78  I = real(I);
79  % figure,imshow(I, []);
80  % -----
81

```

$$g = \frac{1}{1 + |\nabla \hat{I}|^p}$$

이제 앞에서 구한  $\hat{I}$ 의 미분을 구해야한다. 미분은 forward, backward, prewitt, sober filter 등 여러가지 방법으로 구할 수 있으나 이번 과제에선 sobel filter를 사용하였다. Sobel filter를 사용한 이유는 가로, 세로 뿐만 아니라 대각선 방향의 edge도 잘 탐색하기 위해서 이다. 이는 다음과 같이 구현하였다.

```

82 % Derivative code
83 % Get size
84 dimX = size(Img,1);
85 dimY = size(Img,2);
86 % Inititalize
87 dx=zeros(dimX,dimY);
88 dy=zeros(dimX,dimY);
89 % Using sobel filter
90 for x=2:dimX-1
91     for y=2:dimY-1
92         dx(x,y) = (I(x+1, y-1) + 2*I(x+1, y) + I(x+1, y+1) - (I(x-1, y-1) + 2*I(x-1, y) + I(x-1, y+1)))./9;
93         dy(x,y) = ((I(x-1, y+1) + 2*I(x, y+1) + I(x+1, y+1)) - (I(x-1, y-1) + 2*I(x, y-1) + I(x+1, y-1)))./9;
94     end
95 end

```

이번 구현에선 sobel filter를 따로 두고 convolution을 진행하는 것이 아닌, 이중 for 문을 돌면서 각 (x, y) 좌표값 별로 sobel filter를 적용했을 때 사용하는 index를 가져와 해당하는 가중치를 곱해 값을 구하였다.

```

96 % Calculate magnitude
97 magnitude = sqrt(dx.^2 + dy.^2);
98 p=2;
99 g = 1./(1+magnitude.^p);

```

그 다음으로 magnitude 인  $|\nabla \hat{I}|$ 를 다음과 같이 구하였다. 이후  $g = \frac{1}{1 + |\nabla \hat{I}|^p}$  수식에 맞춰서 g를 구하였다.

## 2. levelset\_update.m 코드 설명 (간단한 구현)

$$\begin{aligned} \frac{\partial u}{\partial t} &= g(I)|\nabla u| \operatorname{div} \left( \frac{\nabla u}{|\nabla u|} \right) + cg(I)|\nabla u| \\ &= g(I)(c + \kappa)|\nabla u|, \end{aligned}$$

Level set update를 위해선 왼쪽의 수식을 적용해야 한다. Expanding term인 c는 사전에 미리 설정하기 때문에 해당 함수에선  $|\nabla u|$ 와  $\operatorname{div}(\frac{\nabla u}{|\nabla u|})$ 인 k를 먼저 구해야 한다.

다. 각 term을 구하기에 앞서 미분 함수가 반복적으로 나오기 때문에 아래와 같이 미분 함수인 sobel\_filter를 작성해주

었다. 해당 함수는 위에서 사용했던 sobel filter와 같다.

```

% Sobel filter for derivative
function [dx, dy] = sobel_filter(input)
% Get size
dimX = size(input,1);
dimY = size(input,2);
% Inititalize
dx = zeros(dimX,dimY);
dy = zeros(dimX,dimY);
% Calculate
for x=2:dimX-1
    for y=2:dimY-1
        dx(x,y) = (input(x+1, y-1) + 2*input(x+1, y) + input(x+1, y+1) - (input(x-1, y-1) + 2*input(x-1, y) + input(x-1, y+1)))./9;
        dy(x,y) = ((input(x-1, y+1) + 2*input(x, y+1) + input(x+1, y+1)) - (input(x-1, y-1) + 2*input(x, y-1) + input(x+1, y-1)))./9;
    end
end

```

```

14 % Gradient of phi
15 [phi_dx, phi_dy] = sobel_filter(phi_in);
16 dPhi = sqrt(phi_dx.^2 + phi_dy.^2); % mag(grad(phi))
--

```

먼저  $|\nabla u|$ 를 왼쪽의 코드를 통해서 구현하였다. 해당 코드에서 u는 phi\_in과 같다.

다음으로  $k$ 를 구하기 위해서 divergence 안에 들어갈 normalize 값을 구해야 한다. 이를 위해서 위에서 구한  $\nabla u$ 를  $|\nabla u|$ 로 나누어야 하는데 이때  $|\nabla u|$ 가 0일 경우 분모가 0이 되어 오류가 발생한다. 따라서 epsilon인 eps 변수를 설정해 분모에 더해주어 오류를 방지하였다. Eps는 주로  $1e-4$ 에서  $1e-8$ 를 사용하기에 이번 과제에선  $1e-8$ 로 설정하였다. 이제 divergence를 구해야 한다. 앞에서 구한 normalize 값을 미분하고, 미분 후 나온  $dx, dy$  값을 더하여 divergence인  $k$  (kappa)를 구하였다.

```

18 % Use eps(epsilon) to prevent division by zero
19 % Generally use 1e-4 ~ 1e-8 at deep learning. So I use 1e-8 in this assignment.
20 eps = 1e-8;
21
31 % -----
32 % 간단한 구현
33 % -----
34
35 normalize_phi = (phi_dx + phi_dy)./(dPhi+eps);
36 [divergence_x, divergence_y] = sobel_filter(normalize_phi);
37 kappa = divergence_x + divergence_y; % curvature
--
26 smoothness = g.*kappa.*dPhi;
27 expand = c*g.*dPhi;
28
29 phi_out = phi_out + timestep*(expand + smoothness);

```

Skeleton code에서 제공한 code를 통해 왼쪽의 수식과 같이 update를 진행해 준다.

### 3. 구현 결과 (간단한 구현)



먼저 skeleton code의 default 값인  $dt = 0.8$ ,  $c = 1.0$ 를 사용하여 기본 제공 이미지에 적용한 결과이다. Edge를 거의 잘 탐색하긴 했지만 그림의 아랫 동전에서 아랫 부분 edge가 살짝 잘못 탐지한 것을 볼 수 있다.

Final level set after 400 iterations



$c = 0.8$ 로 낮춘 결과 왼쪽 그림에서 볼 수 있듯이 edge를 잘 탐색한 것을 볼 수 있다.

Final level set after 400 iterations



Test 이미지로 4개의 달 사진을 가져와서 실험해보았다. 해당 사진에선  $dt = 0.8$ ,  $c = 0.6$ 을 사용했을 때 edge를 가장 잘 탐색하였다.

#### 4. 추가적인 levelset\_update.m 코드 설명 (정확한 구현)

$$\begin{aligned}\frac{\partial u}{\partial t} &= g(I)|\nabla u| \operatorname{div} \left( \frac{\nabla u}{|\nabla u|} \right) + cg(I)|\nabla u| \\ &= g(I)(c + \kappa)|\nabla u|,\end{aligned}$$

The curvature of a level set is given by  $\kappa = (u_{xx}u_y^2 - 2u_xu_yu_{xy} + u_{yy}u_x^2)/|\nabla u|^3$ .

기존에 구현했던 divergence는 간단하게 구현 한 것으로 div term 안의 값을  $x$ 와  $y$ 에 대해서 미분한 후 더해준 값을 구했다. 그러나 위의 수식에서 볼 수 있듯이 divergence를 좀 더 정확하게 구하려면 위의 수식을 적용해야 한다. 좀 더 정확한 second-order 미분 값을 구하기 위해 함수를 따로 작성하였고 그 코드는 아래와 같다.

```

63 function [dxx, dyy] = second_derivative(input)
64 % Get size
65 dimX = size(input,1);
66 dimY = size(input,2);
67 % Initialize
68 dxx = zeros(dimX,dimY);
69 dyy = zeros(dimX,dimY);
70 % Calculate
71 for x=2:dimX-1
72     for y=2:dimY-1
73         dxx(x,y) = (input(x+1, y) - 2*input(x, y) + input(x-1, y))/4;
74         dyy(x,y) = (input(x, y+1) - 2*input(x, y) + input(x, y-1))/4;
75     end
76 end
77
78 function [dxy] = cross_second_derivative(input)
79 % Get size
80 dimX = size(input,1);
81 dimY = size(input,2);
82 % Initialize
83 dxy = zeros(dimX,dimY);
84 % Calculate
85 for x=2:dimX-1
86     for y=2:dimY-1
87         dxy(x,y) = (input(x+1, y-1) - input(x+1, y+1) - input(x-1, y-1) + input(x-1, y+1))/4;
88     end

```

추가로 구현한 함수는 총 두 가지로 dxx, dyy를 구하는 second\_derivative와 cross partial derivative인 dxy를 구하는 cross\_second\_derivative 함수 이다. 미분 시 border 부분처리는 가장자리 값과 같은 값을 padding 처리하였다고 가정한다면 변화량이 0이기에 따로 계산해주지 않았다. (초기값이 0이기 때문이다.) 위의 함수를 가지고

```

14 % Gradient of phi
15 [phi_dx, phi_dy] = sobel_filter(phi_in);
16 dPhi = sqrt(phi_dx.^2 + phi_dy.^2); % mag(grad(phi))
17
18 % Use eps(epsilon) to prevent division by zero
19 % Generally use 1e-4 ~ 1e-8 at deep learning. So I use 1e-8 in this assignment.
20 eps = 1e-8;
21
22 % -----
23 % 좀 더 정확한 구현
24 % -----
25
26 [phi_dxx, phi_dyy] = second_derivative(phi_in);
27 phi_dxy = cross_second_derivative(phi_in);
28 div = (phi_dxx.*(phi_dy.^2) - phi_dx.*phi_dy.*phi_dxy + phi_dyy.*(phi_dx.^2)) ./ (dPhi.^3 + eps);
29 kappa = div; % curvature
30


```

divergence의 정확한 값을 구하게 되면 다음과 같다.


위에 나왔던 수식을 그대로 옮겨 작성하였다. 일차 미분은 앞서 작성한 sobel filter를 그대로 활용하였고 이차 미분 시에만 새로 작성한 함수를 사용하였다.

## 5. Divergence의 정확한 구현 결과

$C = 0.2$



$c = 0.5$




$c = 1$




우선 기본 제공 이미지를  $dt = 0.55$ 로 고정하고,  $c$ 의 값만 각각 0.2, 0.5, 1로 설정한 실험 결과이다.  $c$ 의 값이 커질수록 반복 당 expand의 스케일이 더 커지기 때문에 수렴도 더 빨리한다. 그래서  $c$ 가 너무 작으면 수렴하지 못 하고 반면에  $c$ 가 너무 크면 edge를 뚫고 들어간다. 따라서 적절한  $c$ 의 값을 설정하는 것이 중요하다.

$dt = 0.2$



$dt = 0.55$




$dt = 0.8$



$c$ 를 0.5로 고정하고,  $dt$ 의 값만 각각 0.2, 0.55, 0.8로 설정한 실험 결과이다. 마찬가지로  $dt$ 의 값이 커질수록 수렴도 더 빨리한다. 그래서  $dt$ 가 너무 작으면 수렴하지 못 하고 반면에  $dt$ 가 너무 크면 edge를 뚫고 들어간다. 따라서 적절한  $dt$ 의 값을 설정하는 것이 중요하다.





위의 실험 결과에서 볼 수 있듯이 이미지 별로 적절한  $dt$ 와  $c$ 의 값을 설정하는 것이 중요하다. 테스트 용 이미지에서 실험 결과가 가장 잘 나왔던 parameter의 값은  $dt = 0.6$ ,  $c = 0.5$ 이다. 왼쪽 그림에서 볼 수 있듯이 4개의 달의 edge를 잘 탐색한 것을 볼 수 있다.



해당 이미지에서  $dt = 0.7$ ,  $c = 0.7$ 로 높이면 예상한 바와 같이 실제 달의 edge를 뚫고 들어간 모습을 볼 수 있다. 따라서 적절한 값의 설정이 중요함을 다시 한번 확인할 수 있었다.